Общая постановка ML-задач. Пример kNN

Лекторы:
Машталер Максим Кириллович
Аношин Матвей Антонович

Кот или Собака?

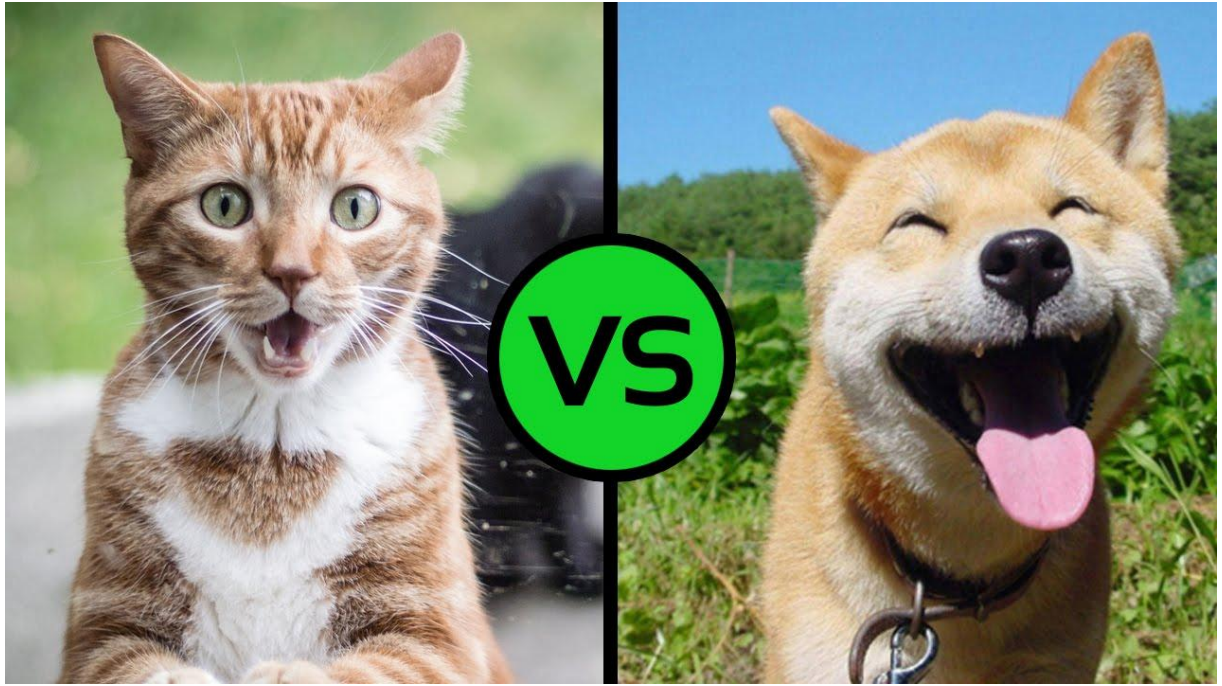

source: https://www.youtube.com/watch?v=JP0SQAQ-PLU

0? 1? … 9?

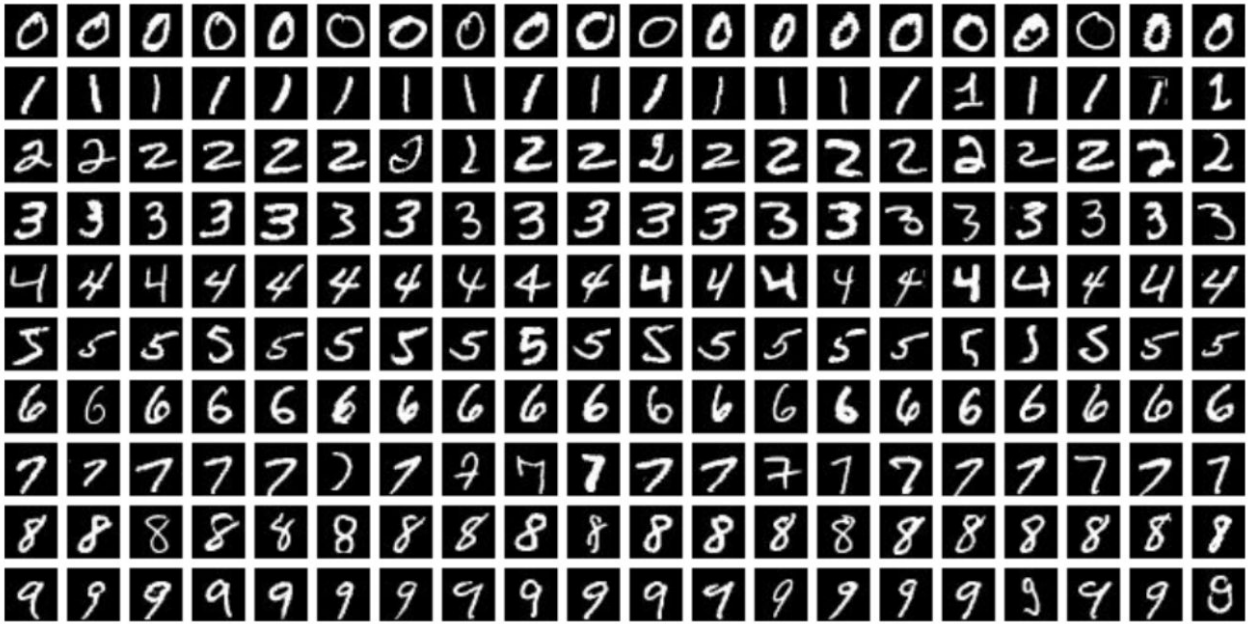

source: https://git-disl.github.io/GTDLBench/datasets/mnist_datasets/

А какой курс будет завтра?

source: https://finance.yahoo.com/quote/AAPL/?guccounter=1

А что такое ML?

Machine Learning (ML) - это наука о том, как обучить компьютер решать полезные задачи из реальной жизни (не хардкодя ответы)

Задачи ML бывают самые разные, например:

- прогнозировать цену на абрикосы на рынке в Адлере
- проклассифицировать меланому на доброкачественность
- найти аномалию в банковских транзакциях
- определить (найти) книгу по ее описанию
- сгенерировать лекарство от рака

Из чего состоит решение ML задачи?

В ML, используя полезные данные (фичи) из области задачи, необходимо обучить модель (как правило очень сложную параметрическую функцию) аппроксимировать целевую переменную.

Для оценки построенного решения используются <u>метрики</u>

Про данные:

Данные в ML получаются, как правило, с помощью разметки (ручной или автоматической) массивов, полученные в индустриальных (e.g., от клиентов) или научных (e.g., с сенсоров) задачах. И получают:

$$\mathcal{D} = \{(X, y)|_{i=1}^{N}\}$$ - данные

$X_i \in \mathbb{R}^f$

$y_i \in \mathbb{R}^l$

- f - размер фич (входов)
- l - размер лейблов (выходов)

$$X \underbrace{\rightarrow}_{F(\theta, \cdot)} y$$

- параметрическая функция (модель)

Про данные:

Для своих задач данные можно брать на:

- Kaggle/ODS/ml contests - соревнования
- Hugging Face - данные для обучения и бенчмарков LLM-ок
- UCI ML - классические датасеты
- ML Commons
- Sklearn

Про работу с данными:

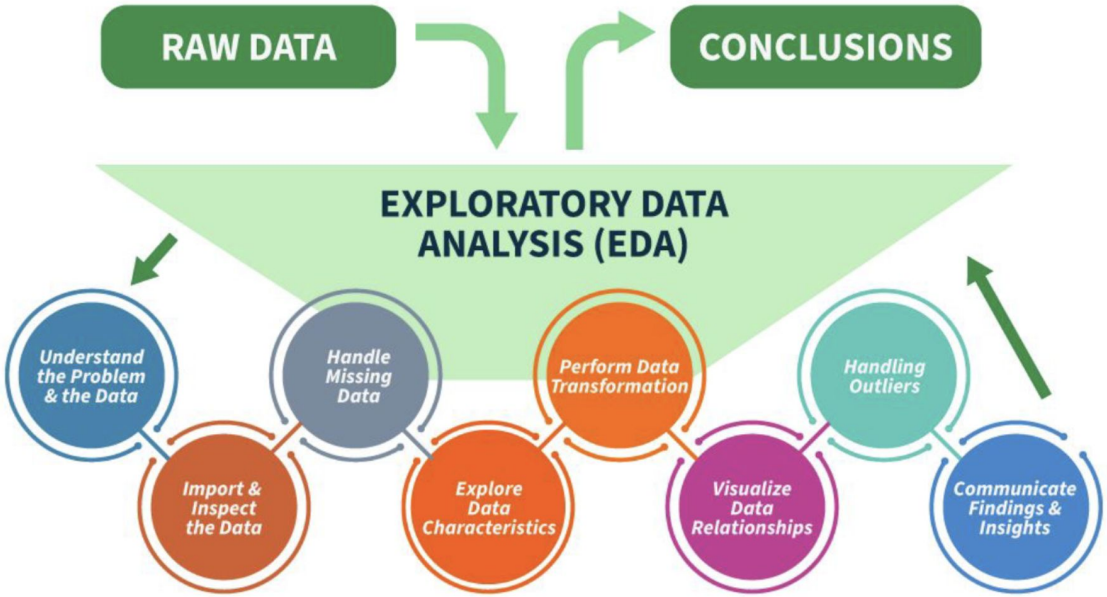

source: https://www.geeksforgeeks.org/what-is-exploratory-data-analysis/

Про критерии качества: метрики vs loss-ы

Метрика

Связь между решением и реальным миром

- Ориентированность на задачу
- Интерпретируемость
- Устойчивость к выбросам
- Известный диапазон значений (как правило “0” - плохо, “1” - хорошо)

Loss/Cost-функция

Связь между моделью и ее оптимизатором (для подбора параметров)

- Классные математические свойства, например дифференцируемость (для SGD)

source: https://education.yandex.ru/handbook/ml/article/metriki-klassifikacii-i-regressii

Классификация: собака vs кот

Попробуем сначала извлечь какой-то признак.
Построим вероятностные плотности для каждого класса.

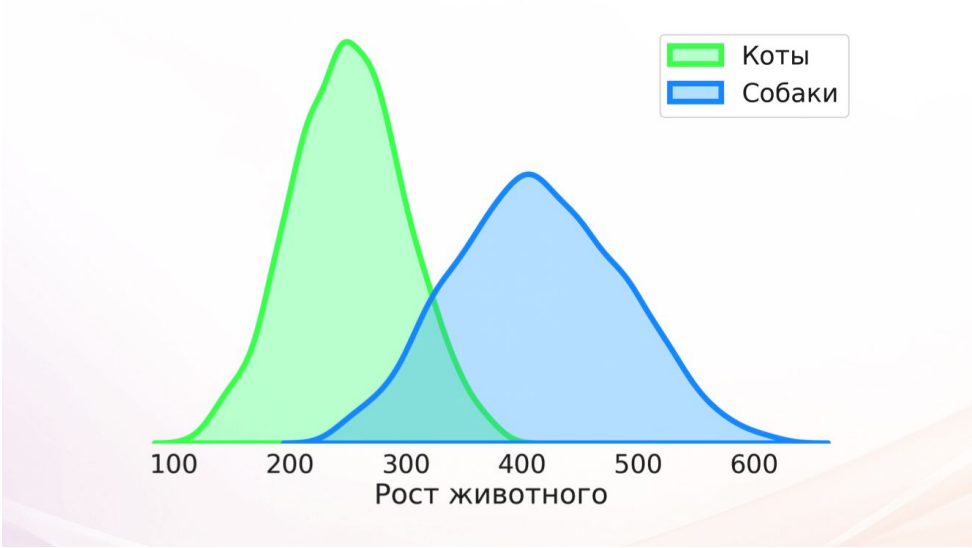

source: https://thetahat.ru/files/ad/main/1/vvad_1.pdf

Классификация: собака vs кот

Извлечем еще один признак — размер ушек.
Теперь классы лучше разделяются.

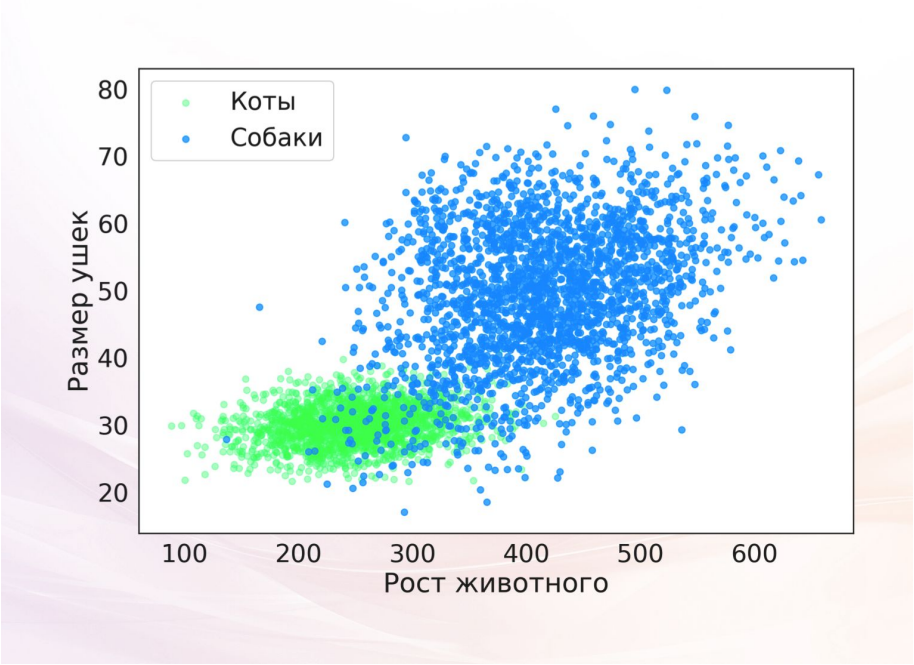

Классификация: собака vs кот

Попробуем классифицировать новое животное.
Кто отмечен красным?

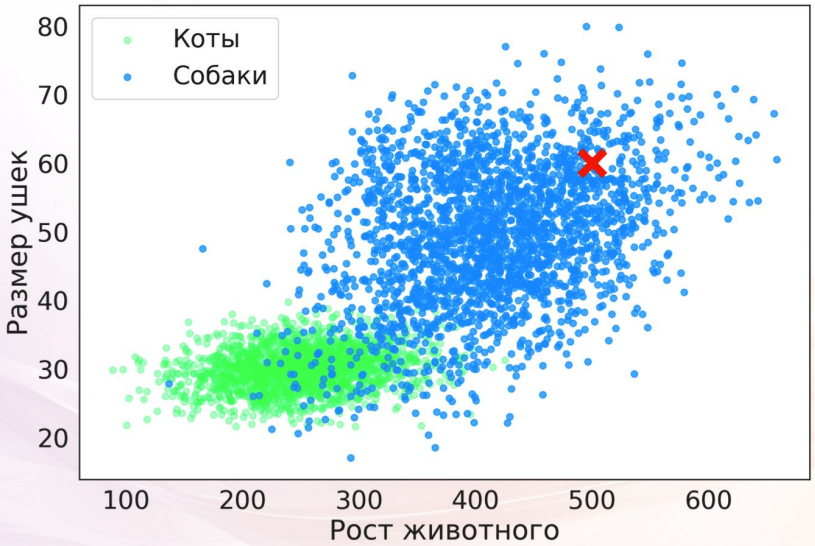

Классификация: собака vs кот

Попробуем классифицировать новое животное.
Кто отмечен красным?

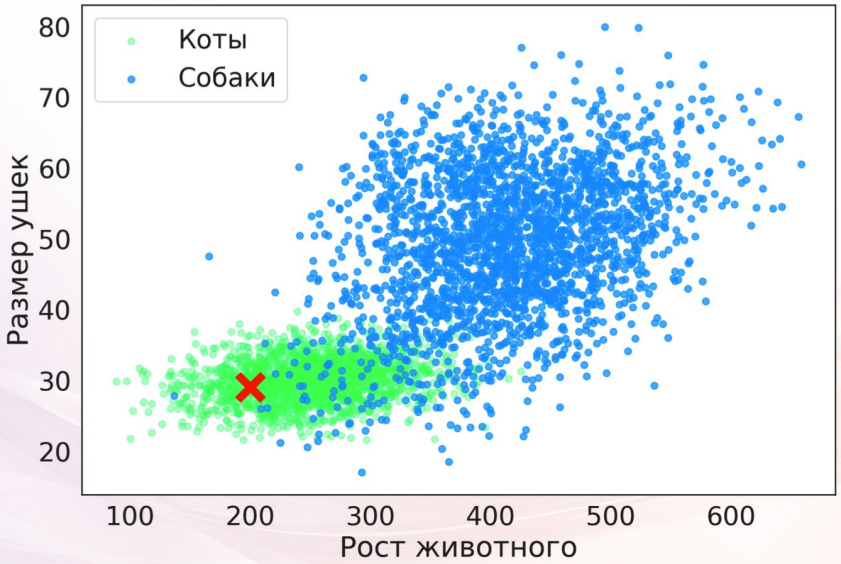

Классификация: собака vs кот

Попробуем классифицировать новое животное.
Кто отмечен красным?

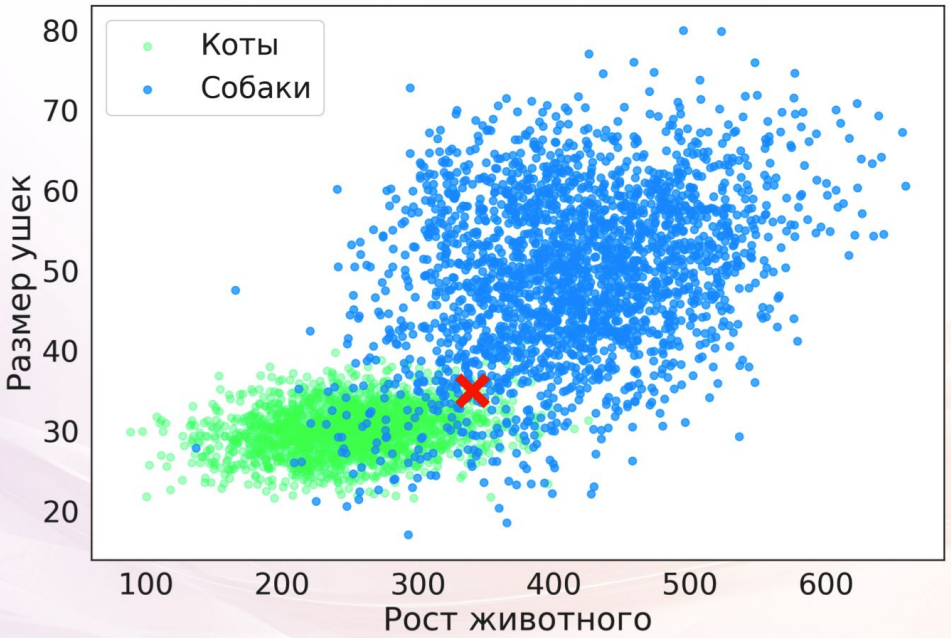

Классификация: собака vs кот

Попробуем классифицировать новое животное.
Кто отмечен красным?

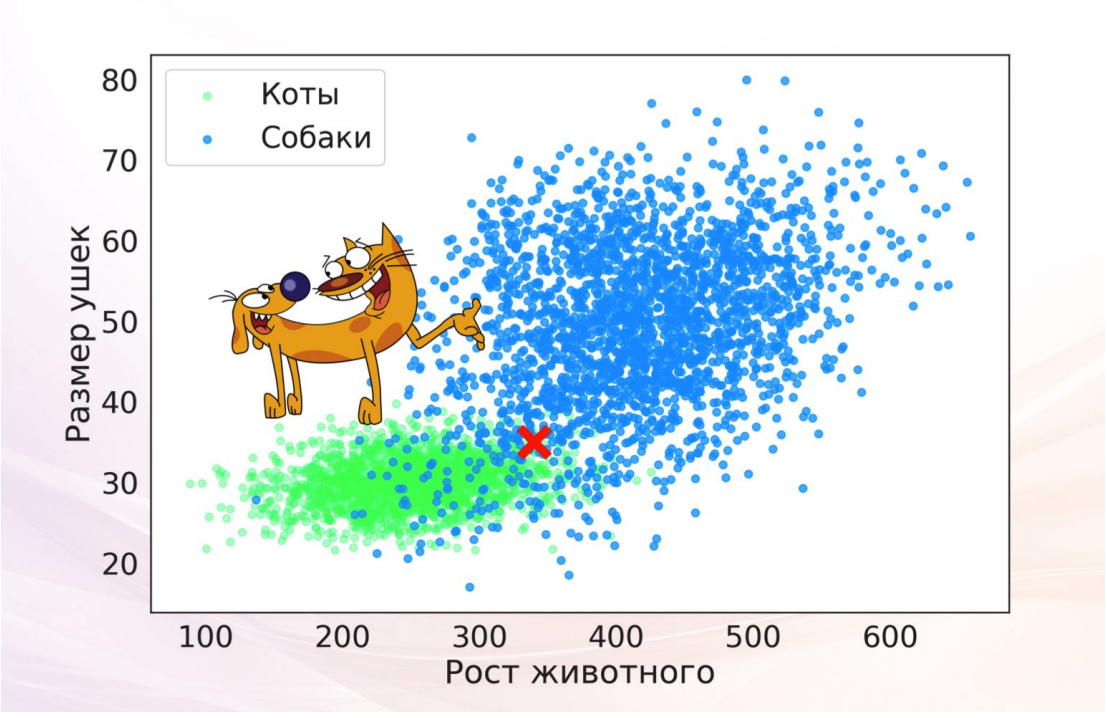

Спасибо за внимание!
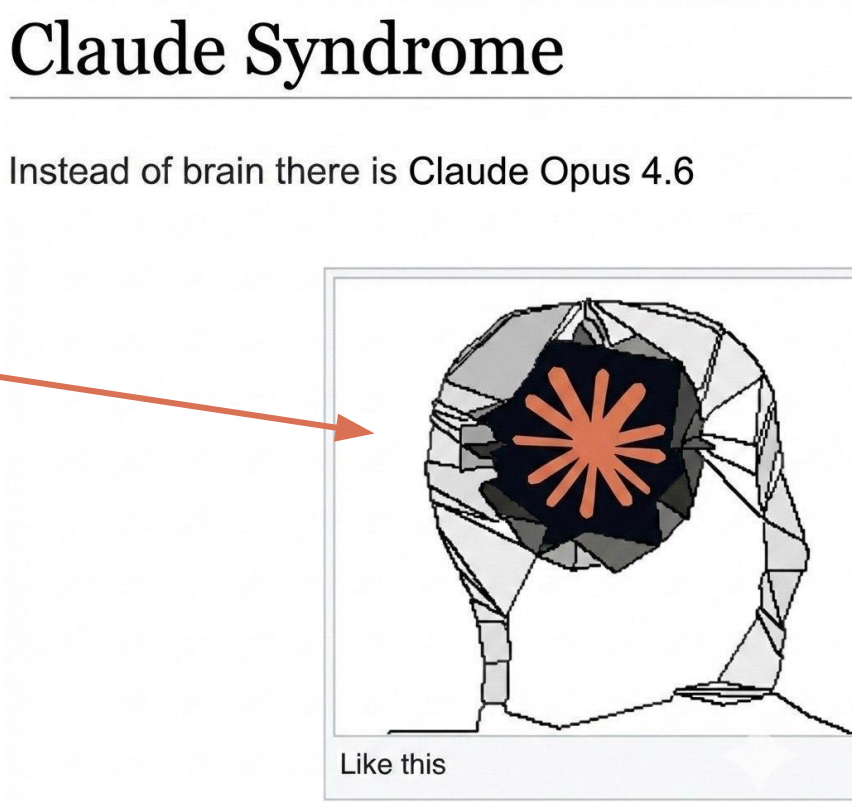
Как делать, ботать и жить не надо :)