Что мы уже умеем?

Линейная модель:

$$y = w^\top x + b$$

Можно использовать для:

- предсказания цены
- температуры
- времени
- других **чисел**

Что мы уже умеем?

Линейная модель:

$$y = w^\top x + b$$

Вопрос:

А если нужно предсказывать категории?

Что мы уже умеем?

Мы научились предсказывать **числа**.

А если задача такая:

- спам / не спам
- болен / здоров
- кликнет / не кликнет

Что предсказывать?

Наивная идея

Давайте просто кодировать классы числами.

Например:

класс	число
кошка	1
собака	2
лиса	3

И использовать линейную регрессию.

Почему это плохо?

Модель считает что

- 3 **в 3 раза больше** 1
- 2 **между** 1 и 3

Но классы **не имеют порядка**.

Это **искусственная структура**.

Почему это плохо?

Модель считает что

- 3 **в 3 раза больше** 1
- 2 **между** 1 и 3

Но классы **не имеют порядка**.

Это **искусственная структура**.

Если модель предсказала:

$$y = 2.4$$

Что это значит?

40% лисы?

60% собаки?

Непонятно, как **трактовать ошибку**

Правильная идея

Вместо числа предсказывать **вероятность класса**

Например:

$$P\left(\text{spam} \mid \text{data}\right) = P\left(y = 1 \mid x\right)$$

Проблема

Вероятность должна быть:

$$0 \leq p \leq 1$$

Проблема

Вероятность должна быть:

$$0 \leq p \leq 1$$

Но линейная модель выдает:

$$(-\infty, +\infty)$$

Проблема

Вероятность должна быть:

$$0 \leq p \leq 1$$

Но линейная модель выдает:

$$(-\infty, +\infty)$$

Нужна функция, которая переводит всю прямую в интервал

$$f : (-\infty, +\infty) \to (0, 1)$$

Проблема

Вероятность должна быть:

$$0 \leq p \leq 1$$

Но линейная модель выдает:

$$(-\infty, +\infty)$$

Нужна функция, которая переводит всю прямую в интервал

$$f : (-\infty, +\infty) \to (0, 1)$$

Можно ли в отрезок?

Переводим прямую в отрезок

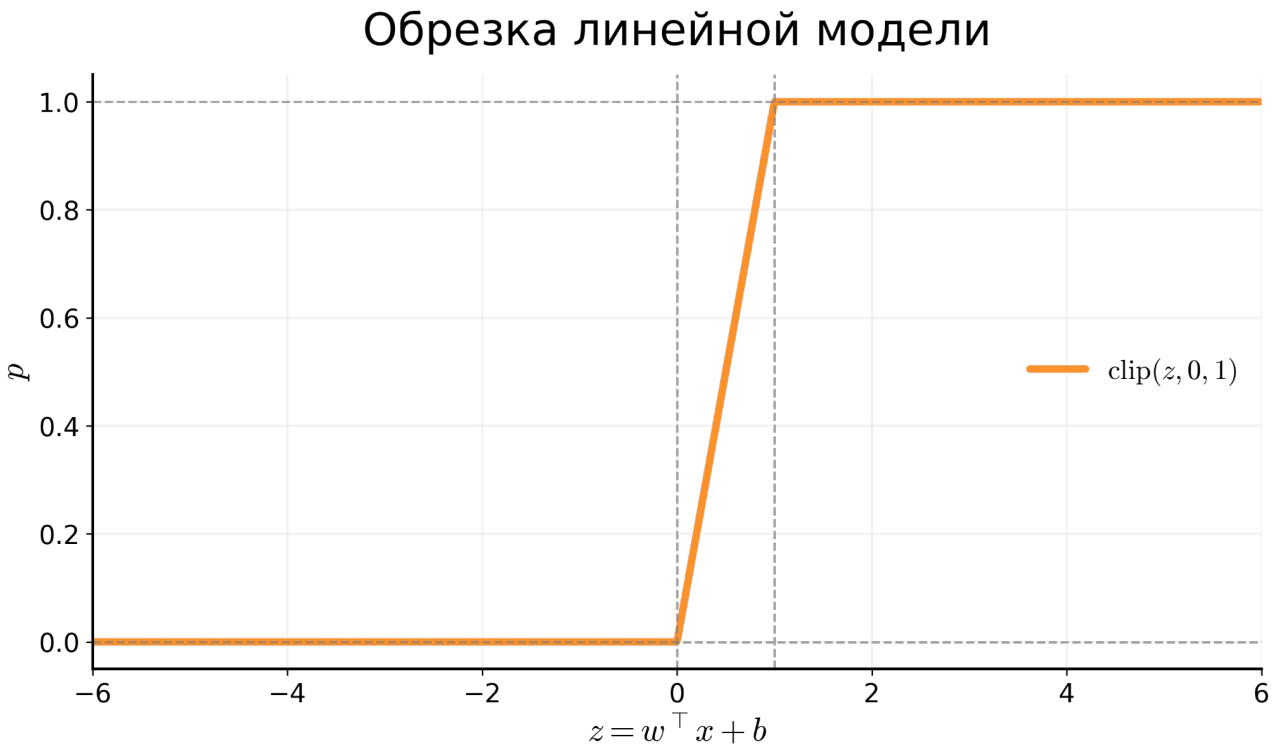

Переводим прямую в отрезок

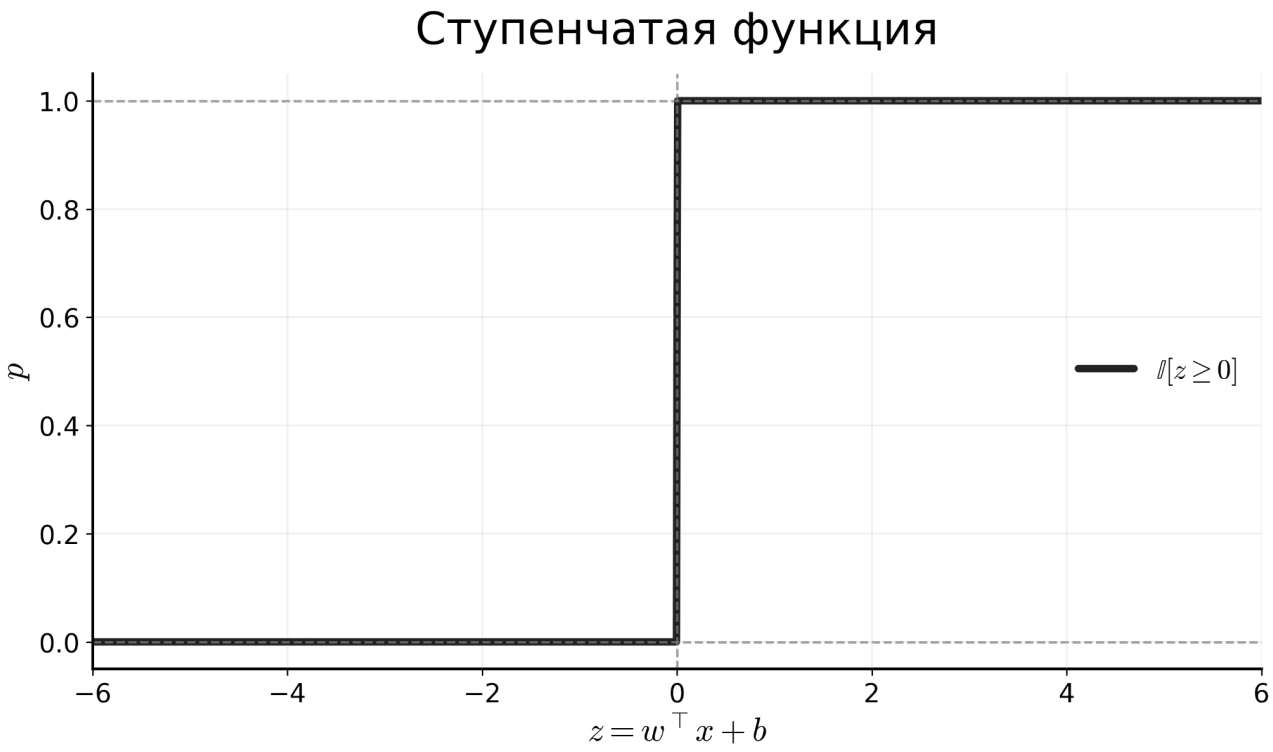

Переводим прямую в отрезок

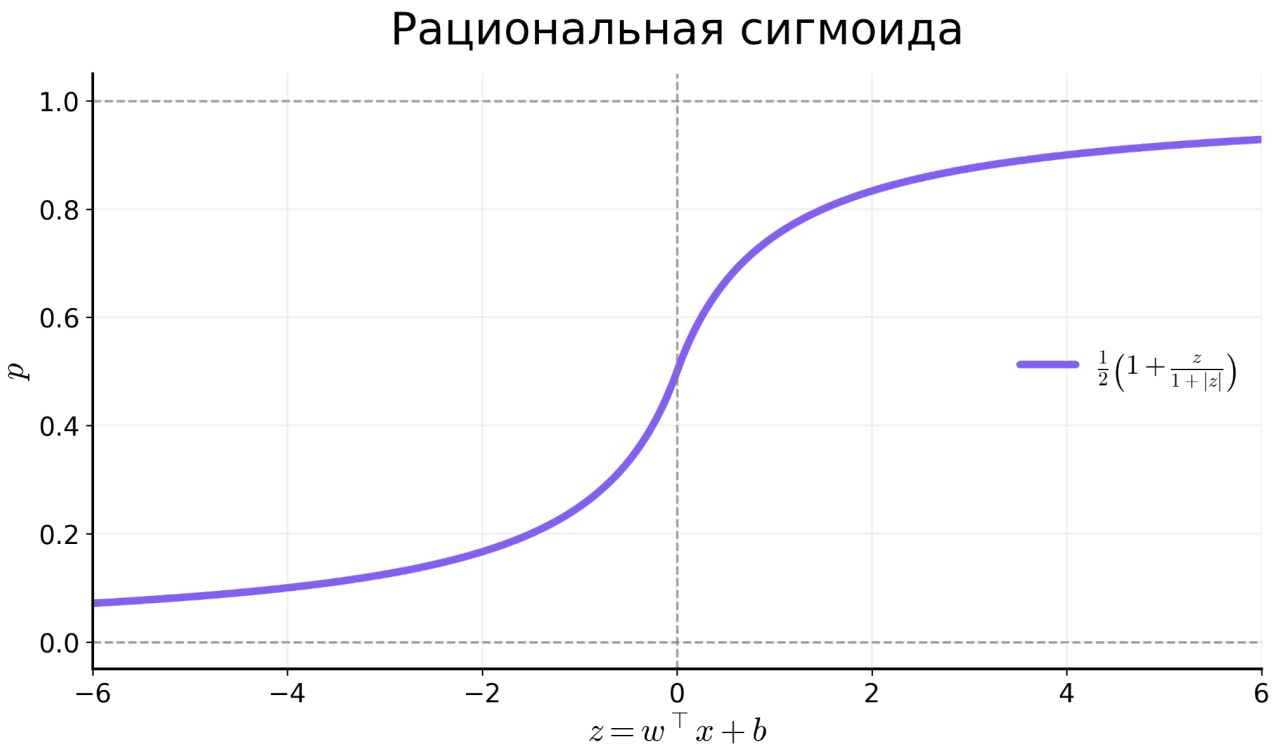

Переводим прямую в отрезок

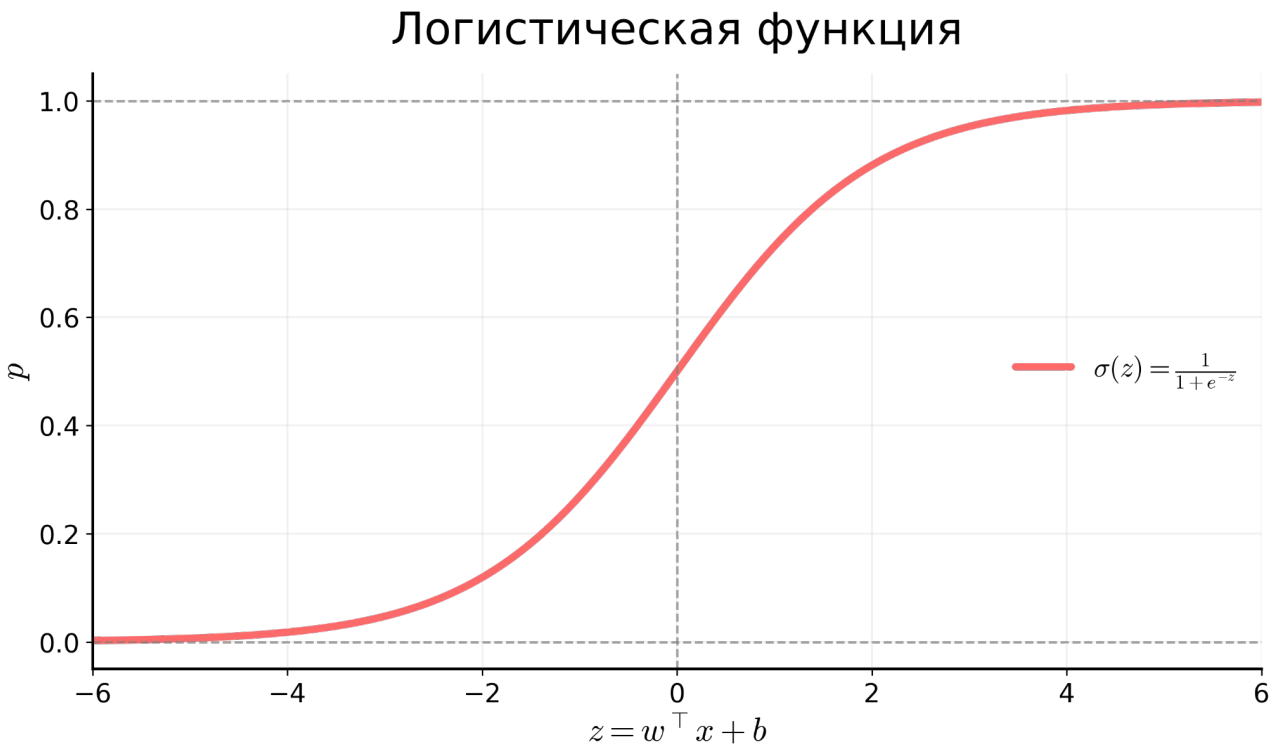

Переводим прямую в отрезок

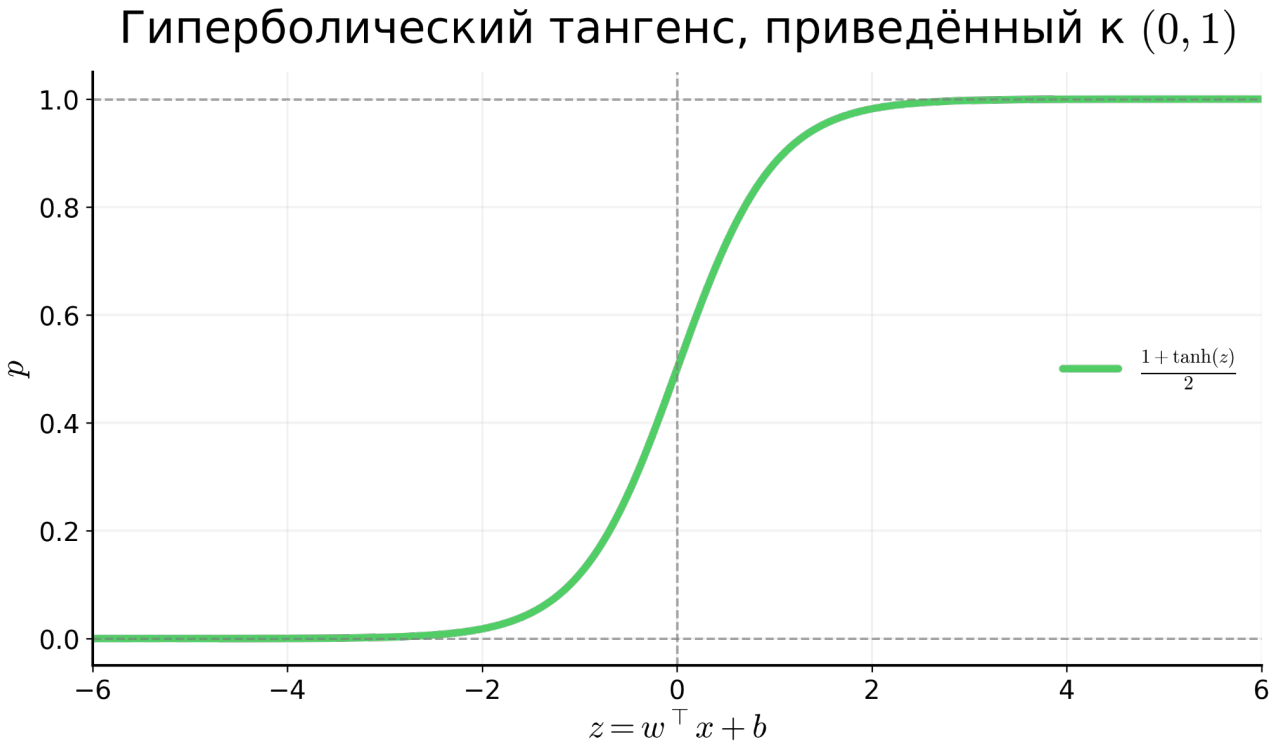

Переводим прямую в отрезок

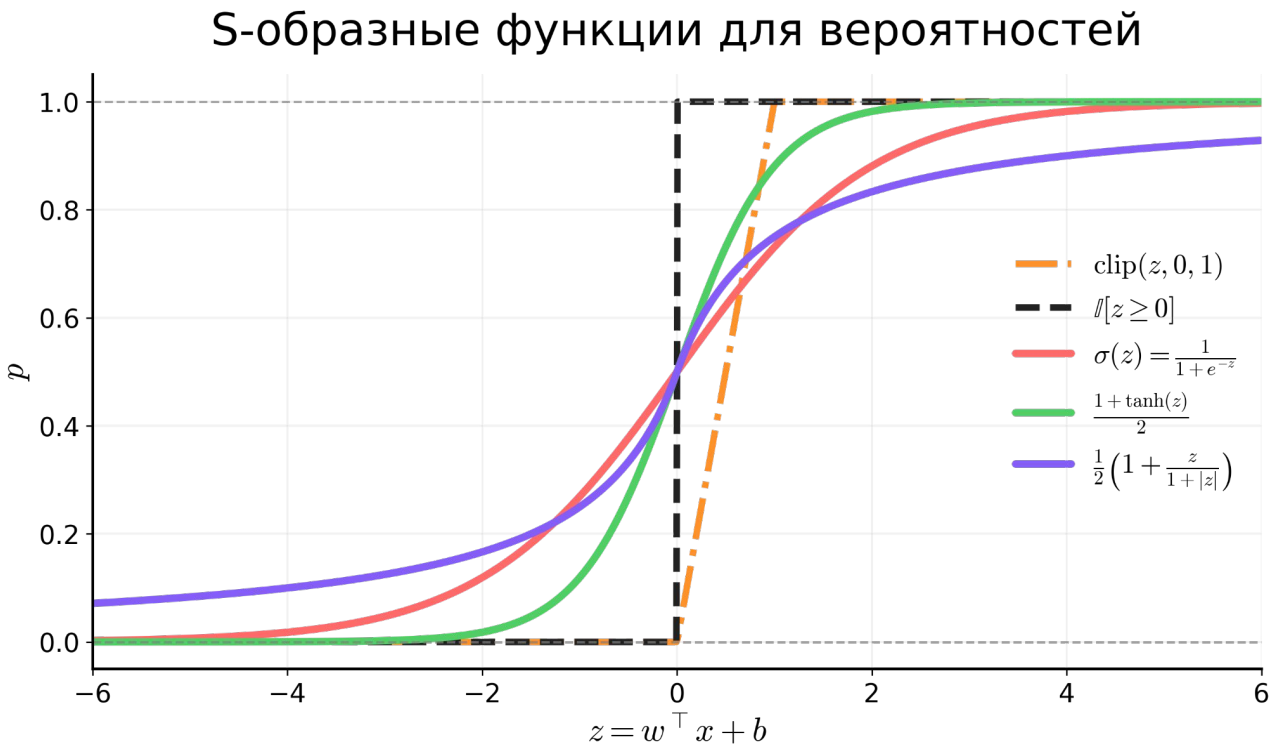

Логистическая сигмоида

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\sigma(-z) = \frac{1}{1 + e^{z}} = \frac{e^{-z}}{e^{-z} + 1} = \frac{1 + e^{-z} - 1}{e^{-z} + 1} = 1 - \frac{1}{e^{-z} + 1} = 1 - \sigma(z)$$

$$\sigma(z)' = -\frac{1 \cdot (1 + e^{-z})'}{(1 + e^{-z})^2} = \frac{1}{(1 + e^{-z})} \cdot \frac{e^{-z}}{(1 + e^{-z})} = \sigma(z) \cdot (1 - \sigma(z))$$

Гиперболический тангенс

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} = \frac{2e^z - (e^z + e^{-z})}{e^z + e^{-z}} = \frac{2}{1 + e^{-2z}} - 1 = 2\sigma(2z) - 1$$

$$\tanh(-z) = \frac{e^{-z} - e^z}{e^{-z} + e^z} = -\frac{e^z - e^{-z}}{e^z + e^{-z}} = -\tanh(z)$$

$$\tanh(z)' = \left(\frac{e^z - e^{-z}}{e^z + e^{-z}}\right)' = \frac{(e^z + e^{-z})^2 - (e^z - e^{-z})^2}{(e^z + e^{-z})^2} = 1 - \tanh^2(z)$$

Производные от наших функций

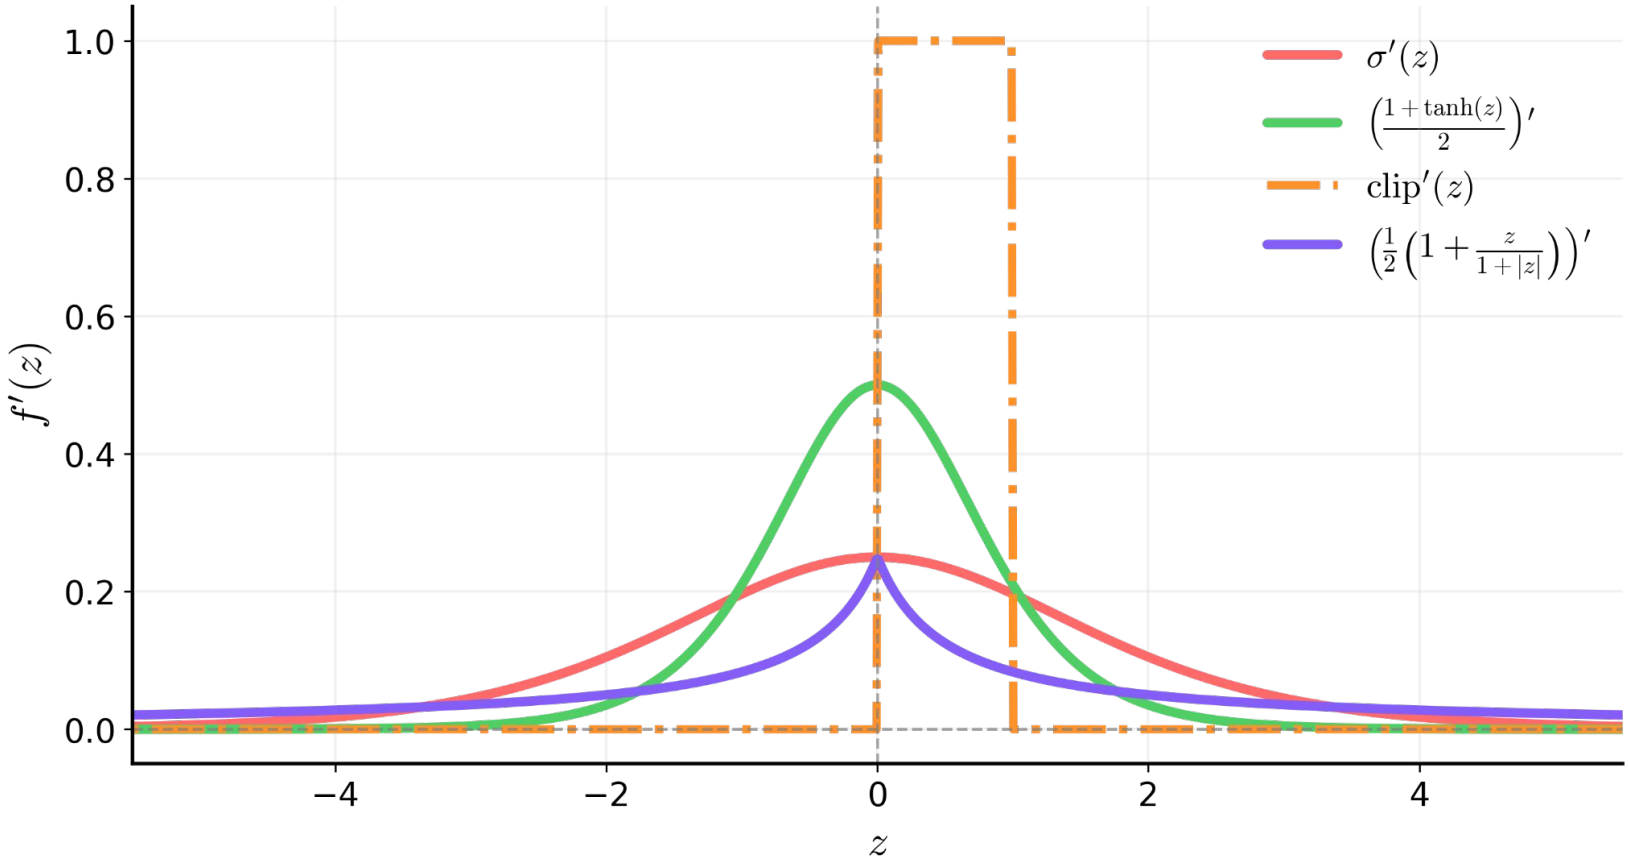

А дальше что?

Модель логистической регрессии

$$z = w^\top x + b$$

Интерпретация:

- линейная модель считает **скор** (его зовут **логит**)

Модель логистической регрессии

$$z = w^\top x + b$$

$$p(y = 1 \mid x) = \sigma(z)$$

Интерпретация:

- линейная модель считает **скор** (его зовут **логит**)
- сигмоида переводит его в ~~не~~**вероятность**

Модель логистической регрессии

$$z = w^\top x + b$$

$$p(y = 1 \mid x) = \sigma(z)$$

$$\hat{y} = 1 \,\text{if}\, p > t \,\text{else}\, 0$$

Интерпретация:

- линейная модель считает **скор** (его зовут **логит**)
- сигмоида переводит его в ~~не~~**вероятность**
- **порог** дает ответ

Геометрия логистической регрессии

Решение границы:

$$z = w^\top x + b = 0$$

Геометрия логистической регрессии

Решение границы:

$$z = w^\top x + b = 0$$

Это гиперплоскость.

$z > 0$ → класс 1

$z < 0$ → класс 0

Здесь могла бы быть ваша реклама или SVM

Оценка качества классификации

Модель классификации предсказывает **класс**.

Чтобы оценить качество, сравниваем:

- **истинный класс**
- **предсказанный класс**

Основой большинства метрик является **матрица ошибок**.

Матрица ошибок (Confusion Matrix)

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

где

- **TP** — True Positive
- **FP** — False Positive
- **FN** — False Negative
- **TN** — True Negative

Accuracy

Доля верных предсказаний

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

Интерпретация: **какая доля объектов классифицирована правильно.**

Precision

Доля верных предсказаний

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

Интерпретация: **среди объектов, которые модель назвала положительными, какая доля действительно положительная.**

Recall

Полнота (чувствительность)

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

Интерпретация: **какую долю всех положительных объектов модель нашла.**

F1-score

Баланс между precision и recall

$$\frac{1}{\mathrm{F}_1} = \frac{1}{2}\left(\frac{1}{\mathrm{Precision}} + \frac{1}{\mathrm{Recall}}\right)$$

F1-score

Баланс между precision и recall

$$\frac{1}{\mathrm{F}_1} = \frac{1}{2}\left(\frac{1}{\mathrm{Precision}} + \frac{1}{\mathrm{Recall}}\right) \qquad \mathrm{F}_1 = \frac{2\mathrm{TP}}{2\mathrm{TP} + \mathrm{FP} + \mathrm{FN}}$$

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

Почему accuracy может быть плохой

Рассмотрим несбалансированную задачу:

- 99% объектов класса 0
- 1% объектов класса 1

Модель всегда предсказывает 0.

Почему accuracy может быть плохой

Рассмотрим несбалансированную задачу:

- 99% объектов класса 0
- 1% объектов класса 1

Модель всегда предсказывает 0.

$$\text{Accuracy} = 0.99$$

но модель **ничего не находит**. Поэтому используют **precision, recall, F1**.

ROC-кривая

ROC показывает зависимость TPR vs FPR при изменении порога

$$\mathrm{TPR} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

$$\mathrm{FPR} = \frac{\mathrm{FP}}{\mathrm{FP} + \mathrm{TN}}$$

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

	предсказано 1	**предсказано 0**
истинно 1	TP	FN
истинно 0	FP	TN

ROC-AUC

Площадь под ROC-кривой (AUC – Area Under the Curve)

$$\mathrm{AUC} \in [0, 1]$$

Интерпретация:**вероятность того, что модель даст больший скор случайному положительному объекту, чем отрицательному.**

Почему?

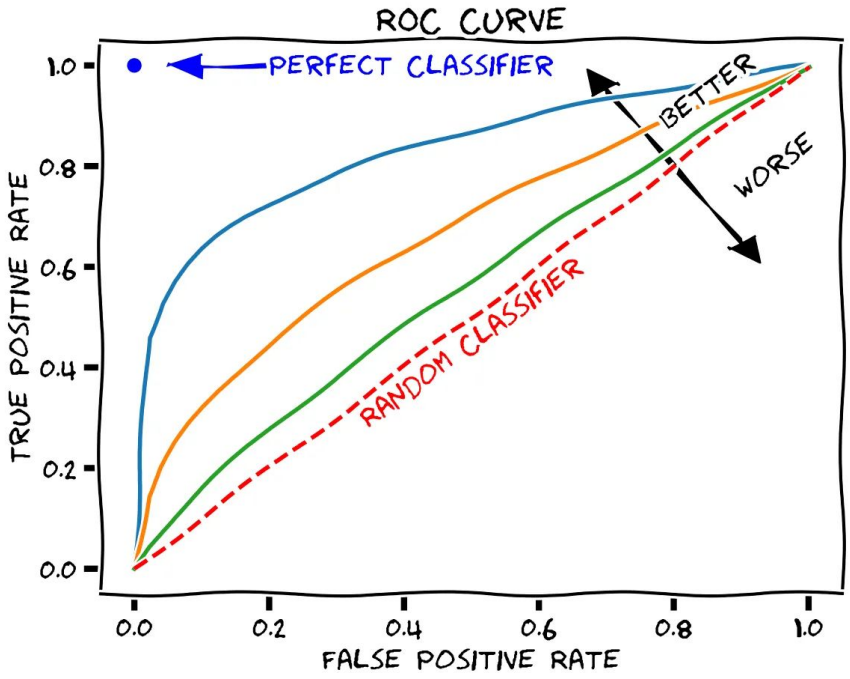

Количество классов

Если 1 класс –

Количество классов

Если 1 класс – ROC-AUC 100% WOW!!!

Количество классов

Если 1 класс – ROC-AUC 100% WOW!!!

Если 2 класса –

Количество классов

Если 1 класс – ROC-AUC 100% WOW!!!

Если 2 класса – выход линейной модели одно число, оцениваем вероятность первого класса

Количество классов

Если 1 класс – ROC-AUC 100% WOW!!!

Если 2 класса – выход линейной модели одно число, оцениваем вероятность первого класса

Если N классов –

Количество классов

Если 1 класс – ROC-AUC 100% WOW!!!

Если 2 класса – выход линейной модели одно число, оцениваем вероятность первого класса

Если N классов – N выходов, но что делать…

Softmax

Если классов N, линейная модель выдаёт N логитов $z_1, z_2, \ldots$

Как сделать вероятности?

Softmax

Если классов N, линейная модель выдаёт N логитов $z_1, z_2, \ldots$

Как сделать вероятности?

Экспонента (делает > 0) + нормировка (сумма = 1)

$$p_k = \frac{e^{z_k}}{\sum e^{z_k}}$$

Softmax

Если классов N, линейная модель выдаёт N логитов $z_1, z_2, \ldots$

Как сделать вероятности?

Экспонента (делает > 0) + нормировка (сумма = 1)

$$p_k = \frac{e^{z_k}}{\sum e^{z_k}}$$

Как это связано с сигмоидой?

Softmax

Если классов N, линейная модель выдаёт N логитов $z_1, z_2, \ldots$

Как сделать вероятности?

Экспонента (делает > 0) + нормировка (сумма = 1)

$$p_k = \frac{e^{z_k}}{\sum e^{z_k}}$$

Как это связано с сигмоидой? $\sigma(x) = \mathrm{Softmax}(0, x)$

Почему MAX

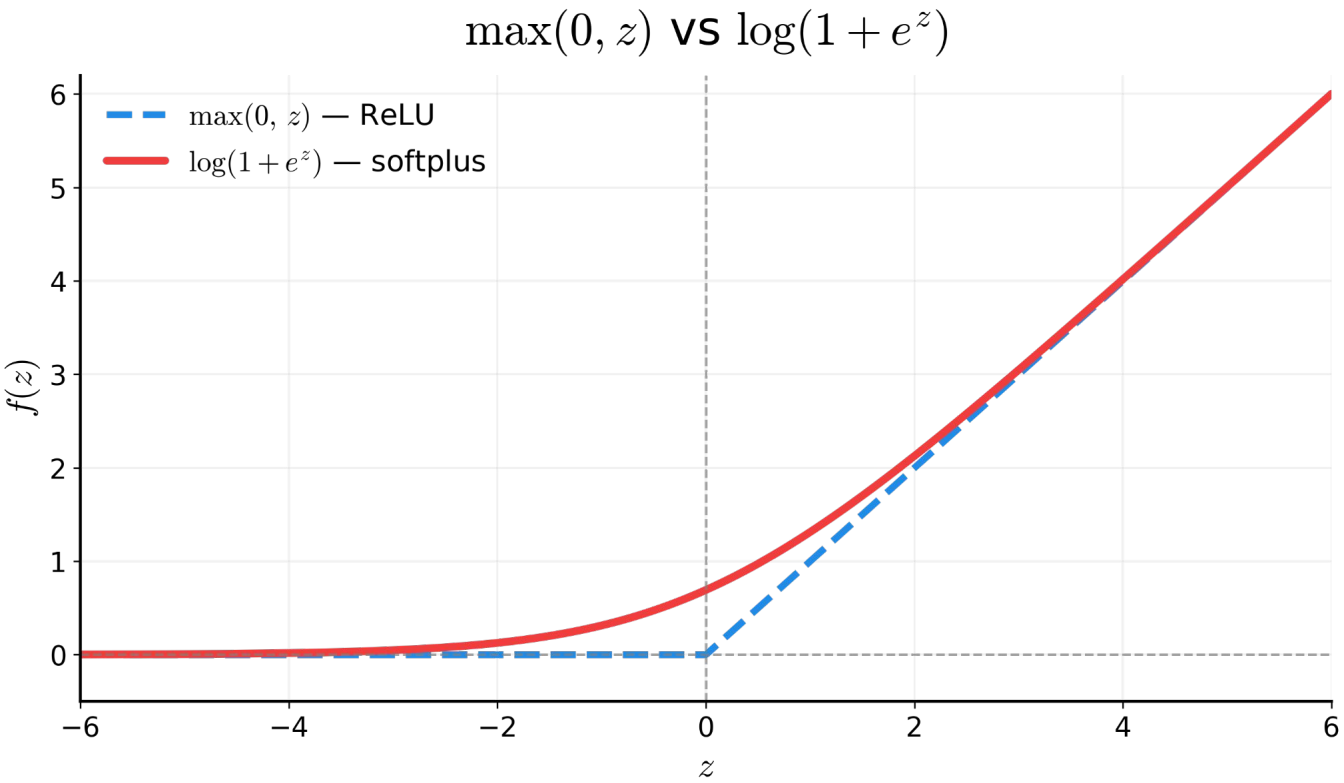
$\max(0, z)$ vs $\log(1 + e^z)$
$\max(0,\ z)$ — ReLU
$\log(1 + e^z)$ — softplus
$f(z)$
z
6
5
4
3
2
1
0
−6
−4
−2
0
2
4
6

Гладкий argmax

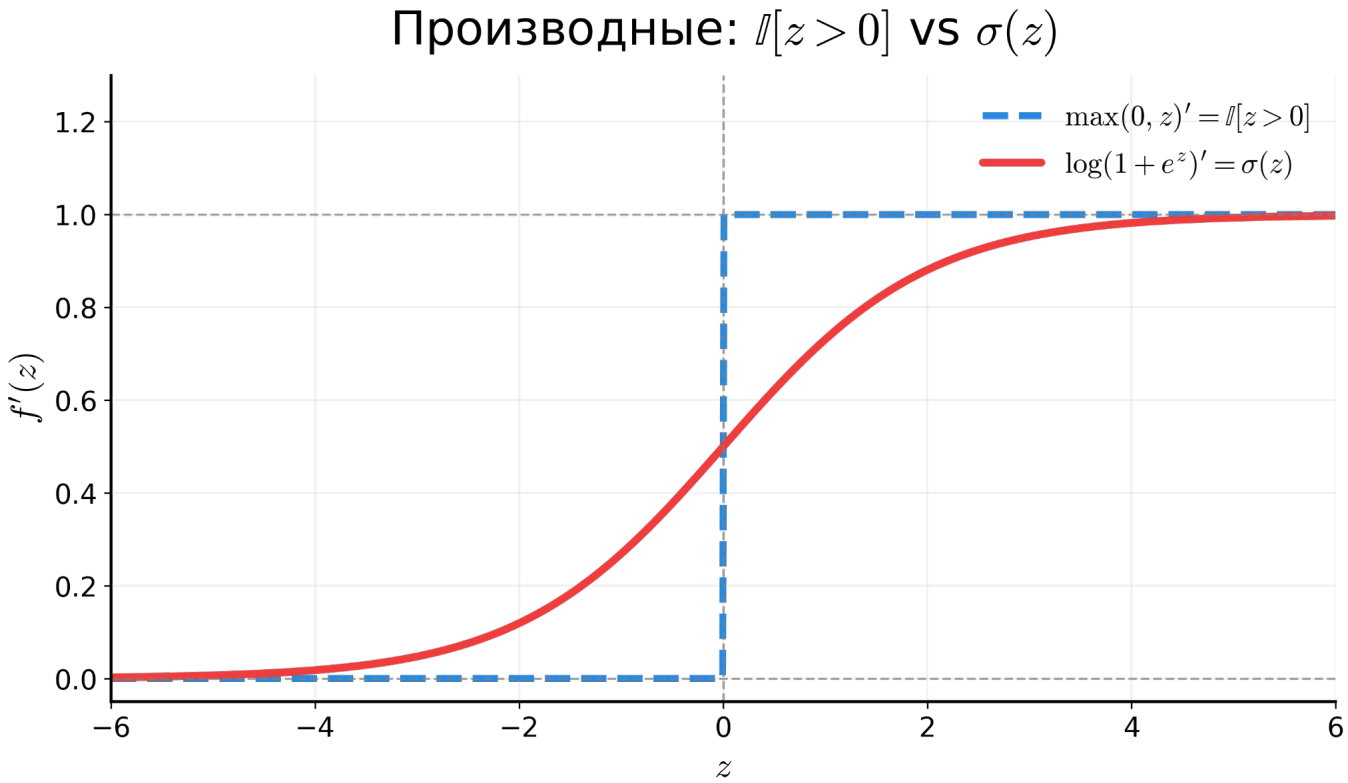

Подумаем о числах

Если у нас логиты

$$z_1 = 1\,000\,000\,000\,000$$
$$z_2 = 999\,999\,999\,999$$

чему равно распределение вероятностей?

Для 2 классов мы предсказываем 1 число. Как его выразить через логиты?

Подумаем о числах

Если у нас логиты

$$z_1 = 1\,000\,000\,000\,000$$
$$z_2 = 999\,999\,999\,999$$

чему равно распределение вероятностей?

Для 2 классов мы предсказываем 1 число. Как его выразить через логиты?

$$z_1 - z_2$$

А можно иначе?

Можно.

А можно иначе?

Можно.

- Один против каждого (OvsA)

А можно иначе?

Можно.

- Один против каждого (OvsA)
- Каждый против каждого (AvsA)

А можно иначе?

Можно.

- Один против каждого (OvsA)
- Каждый против каждого (AvsA)

Но для лог. регрессии это не актуально